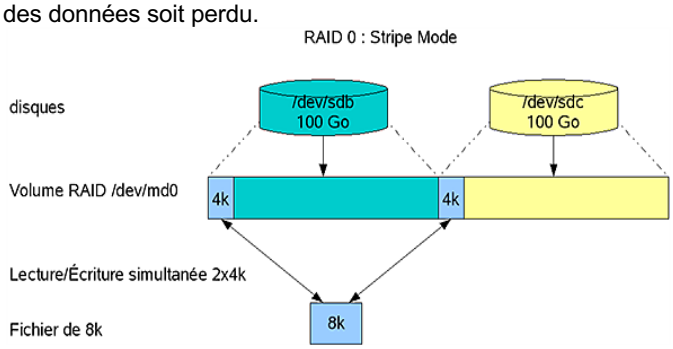
Chapitre 7 : Partitionnement avancé RAID

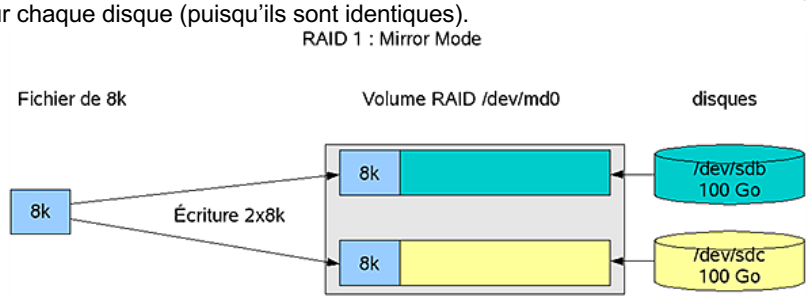
1. Définitions

Le **RAID** (*Redundant Array of Inexpansive Disks*) a été défini par l'université de Berkeley en 1987 dans le double but de réduire les coûts et d'augmenter la fiabilité du stockage des données. Le but est de combiner plusieurs petits disques physiques indépendants en une matrice (array : tableau) de disques dont la capacité dépasse celle du SLED (*Single Large Expensive Drive*). Une matrice apparaît comme une unité logique de stockage unique. Le RAID est tolérant aux pannes en stockant de façon redondante ses informations selon plusieurs méthodes :

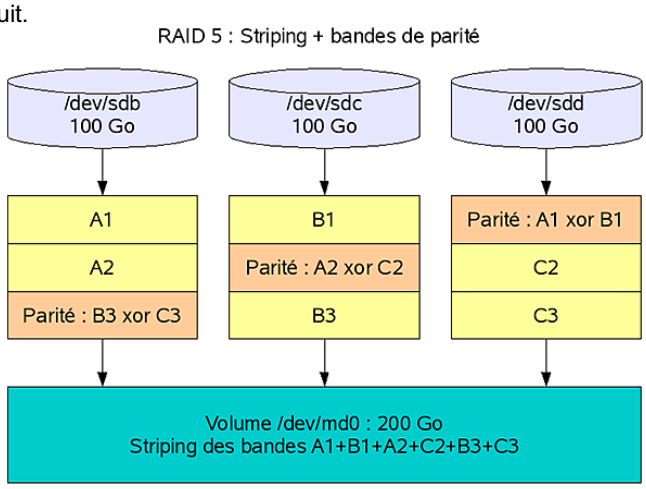
• **RAID-0** (appelé **stripe mode**) : deux disques au moins forment un seul volume et les deux disques ont en principe la même taille. Chaque opération de lecture/écriture sera fractionnée et effectuée sur chacun des disques. Par exemple, 4 ko seront écrits sur le disque 0, 4 ko sur le disque 1, 4 ko sur le disque 2, puis 4 ko sur le disque 0, etc. Ainsi, les performances sont accrues puisque les opérations de lecture et d'écriture sont effectuées en parallèle sur les disques. Le RAID-0 n'a aucune redondance et en cas de panne d'un des disques, il est probable que l'ensemble des données soit perdu.



• **RAID-1** (appelé **mirroring**) : c'est le premier mode redondant car il peut être utilisé à partir de deux disques ou plus avec d'éventuels disques de secours (*Spare Disk*). Chaque information écrite sur un disque est dupliquée sur les autres. Si (N-1) disques du RAID tombent en panne, les données restent intactes. Si un disque de secours est présent, en cas de panne, il est automatiquement reconstruit et prend la place du disque défaillant. Les performances en écriture peuvent être mauvaises : écriture sur N disques en même temps, risquant de saturer le contrôleur disque et le bus. Les performances en lecture sont bonnes, car RAID emploie un algorithme qui peut lire les données sur chaque disque (puisqu'ils sont identiques).



• **RAID-5** : RAID avec bande de parité redistribuée, il s'agit du mode le plus utilisé car il offre le meilleur compromis entre le nombre de disques, l'espace disponible et la redondance. Il faut au moins trois disques avec d'éventuels disques de secours. La parité est présente sur chacun des disques. La taille finale est celle de (N-1) disques. Le RAID-5 tolère une panne de disque, dans ce cas si un disque de secours est présent, il sera automatiquement reconstruit.



2. Considérations d'usage RAID

2.a. Disque de secours

Un disque de secours (***Spare Disk***) ne fait pas partie intégrante d'une matrice RAID tant qu'un disque ne tombe pas en panne. Si cela arrive, le disque est marqué défectueux et le premier disque ***Spare*** qui le remplace.

2.b. Disque défectueux

Un disque défectueux (***Faulty Disk***) est un disque qui a été reconnu en panne par le RAID. Dans ce cas, RAID utilise le premier disque ***Spare*** pour reconstruire sa matrice. Les disques ***Faulty*** appartiennent toujours à la matrice mais sont désactivés.

2.c. Boot

La partition de boot (celle qui contient le noyau, la configuration du **bootloader *GRUB***, les fichiers images de disques) ne doit pas être placée dans une matrice RAID : le chargeur de démarrage est incapable de monter des partitions RAID.

3.e. Périphériques

Une matrice RAID est reconnue par le système comme un périphérique de type bloc, comme n'importe quel disque physique. Ainsi, un RAID peut être constitué avec des disques, des partitions (généralement, on crée une unique partition sur chaque disque). Le bus n'a aucune importance : vous pouvez construire une matrice RAID avec des disques SCSI et IDE mélangés. Les périphériques RAID sont sous la forme : **`/dev/md0`**, **`/dev/md1…`**

3. L'outil mdadm

Afin de créer des matrices RAID, il faut que les partitions qui vont servir à créer la matrice soient de type **0xFD** (Linux RAID autodetect). Les partitions doivent être logiquement sur des disques différents, mais pour des tests, le support RAID autorise des partitions sur le même disque. Dans ce cas, les partitions doivent posséder la même taille.

L'outil `mdadm` permet d'effectuer l'ensemble des opérations sur les volumes RAID (Création, désactivation, suppression,…). Son fichier de configuration est `/etc/mdadm.conf`.

3.a. Création et désactivation d'un volume RAID

*Syntaxe de la commande `mdadm` pour la création ou la désactivation de volume RAID :

```
mdadm action volume -l niveau -n nombre_disques stockages
```

action	-C ou **- -create** : crée un volume RAID.
	-S ou **- -stop** : désactive un volume RAID et libère ses ressources.
volume	Le fichier spécial de type bloc à créer pour représenter le nouveau volume RAID. Souvent `/dev/mdx`, mais peut être un nom quelconque.
niveau	Valeur du niveau de RAID, généralement 0, 1 ou 5. L'option **- -level=raidx** peut être utilisée
nombre_disques	Nombre d'espaces de stockage à employer, suivi des fichiers de blocs représentant ces espaces. L'option **- -raid-devices=N** peut être utilisée
stockages	Les périphériques de stockages séparés par des espaces et désignés par leur fichier spécial en mode bloc.

**Exemple de création d'un volume RAID1 :*

On exploite deux disques durs `/dev/sdb` et `/dev/sdc` pour créer un volume RAID1

```
root@serveur# mdadm -C /dev/md0 -l 1 -n 2 /dev/sdb /dev/sdc
mdadm: array /dev/md0 started
root@serveur# mkfs -t ext3 /dev/md0
```

Remarque :

Les partitions constituant les disques de secours doivent être écrites après l'option `--spare-devices` et suivant le nombre indiqué dans cette option.

```
# mdadm --create /dev/md0 --level=raid0 --raid-devices=2 /dev/sdb1
/dev/sdc1 --spare-devices=1 /dev/sdd1
```

3.b. Sauvegarde de la configuration RAID

On peut créer (ce n'est pas obligatoire) le fichier de configuration `/etc/mdadm.conf`, ce fichier peut être créé manuellement mais l'outil `mdadm` peut le générer automatiquement après la création des matrices RAID avec les commandes suivantes :

```
# echo "partitions des volumes RAID" > /etc/mdadm.conf
# mdadm --detail –scan >> /etc/mdadm.conf
```

4. État du volume RAID

Le fichier virtuel `/proc/mdstat` contient des informations sur le RAID. C'est dans ce fichier qu'on trouve les détails d'un volume RAID, notamment si un des volumes de la matrice est défectueux (Faulty).

La commande **watch** permet de vérifier un état en continu :

```
# watch cat /proc/mdstat
```

On peut aussi utiliser **mdadm** avec le paramètre `--detail` :

```
# mdadm --detail /dev/md0
/dev/md0:
Version : 00.90.01
Creation Time : Mon Jan 23 22:10:20 2006
Raid Level : raid1
Array Size : 104320 (101.88 MiB 106.82 MB)
Device Size : 104320 (101.88 MiB 106.82 MB)
Raid Devices : 2
Total Devices : 3
Preferred Minor : 1
Persistence : Superblock is persistent
Update Time : Mon Jan 23 22:13:06 2006
State : clean
Active Devices : 2
Working Devices : 3
Failed Devices : 0
Spare Devices : 1
Number Major Minor RaidDevice State
0 3 8 0 active sync /dev/hda8
1 3 9 1 active sync /dev/hda9
2 3 10 -1 spare /dev/hda10
UUID : 90e838b5:936f18c7:39f665d3:d9dad1a9
Events : 0.4
```

5. Simulation d'une panne d'un disque RAID

Pour simuler une panne sur `/dev/hda8` on doit utiliser l'option -f :

```
# mdadm /dev/md0 -f /dev/hda8
mdadm: set /dev/hda8 faulty in /dev/md0
```

On peut visualiser l'état du RAID dans `/proc/mdstat` durant l'exécution :

```
md0 : active raid1 hda10[2] hda9[1] hda8[0](F)
104320 blocks [2/1] [U_]
[=> ] recovery = 8.8% (9216/104320) finish=0.1min
speed=9216K/sec
```

Remarquez qu'un « (F) » est apparu près de `hda8,` indiquant un disque ***Faulty***. On voit aussi que sur les deux disques, un est en panne et que le RAID reconstruit sa matrice avec le ***spare disk***. Après l'exécution, vous obtenez :

```
md0 : active raid1 hda10[1] hda9[0] hda8[2](F)
104320 blocks [2/2] [UU]
```

Le RAID est reconstruit automatiquement d'après le résultat de la commande **mdadm --detail /dev/md0 :**

```
# mdadm --detail /dev/md0
...
State : clean
Active Devices : 2
Working Devices : 2
Failed Devices : 1
Spare Devices : 0
Number  Major    Minor  RaidDevice State

0       3        9       0         active sync   /dev/hda9

1       3        10      1         active sync   /dev/hda10
```

```
2       3       8       -1          faulty        /dev/hda8
```

Le disque Faulty est bien **/dev/hda8** et **/dev/hda10** a pris sa place en tant que disque de secours. Ainsi, le disque de secours devient un disque RAID de la matrice.

6. Remplacement d'un disque RAID

Puisque **/dev/hda8** est en panne, on doit le remplacer, mais avant on doit le retirer avec l'option -r (ou --remove) :

```
# mdadm /dev/md0 -r /dev/hda8
mdadm: hot removed /dev/hda8
# cat /proc/mdstat
Personalities : [raid1]
md0 : active raid1 hda10[1] hda9[0]
104320 blocks [2/2] [UU]
```

Puisque /dev/hda8 ne figure plus dans la liste, on peut éteindre la machine puis remplacer le disque défaillant. Puis rallumer la machine, puis repartitionner le disque correctement. Il n'y a plus qu'à rajouter le disque réparé dans la matrice RAID avec l'option -a (--add) :

```
# mdadm /dev/md0 -a /dev/hda8
mdadm: hot added /dev/hda8
# cat /proc/mdstat
Personalities : [raid1]
md0 : active raid1 hda8[2] hda10[1] hda9[0]
104320 blocks [2/2] [UU]

# mdadm --detail /dev/md0
State : clean
Active Devices : 2
Working Devices : 3
Failed Devices : 0
Spare Devices : 1
Number Major Minor RaidDevice State
0 3 9 0 active sync /dev/hda9
1 3 10 1 active sync /dev/hda10
2 3 8 -1 spare /dev/hda8
...
```

Le disque **/dev/hda8** a été remis et est devenu le nouveau disque de secours.

7. Arrêt et redémarrage manuels des volumes RAID

On peut arrêter ponctuellement une matrice RAID avec l'option -S (--stop) après avoir démonté le périphérique :

```
# mdadm --stop /dev/md0
```

Et on redémarre une matrice RAID avec l'option -As (--assemble -scan), cela implique que le fichier /etc/mdadm.conf est correctement renseigné (--scan recherche les informations du volume RAID).

```
# mdadm --assemble --scan /dev/md0
```

Si le RAID ne redémarre pas, vous pouvez tenter avec -R (--run) : il est probable qu'il manque un disque ou qu'une reconstruction du volume RAID en cours n'est pas encore terminée :

```
# mdadm --run /dev/md0
```

8. Suppression définitive d'un volume RAID

Pour supprimer définitivement le volume RAID, il faut supprimer les informations des superblocs des disques composant le RAID. C'est là que sont écrites les informations sur le volume RAID, la suppression de ces informations s'effectue avec l'option --zero-superblock :

```
# mdadm --zero-superblock /dev/sdb2 /dev/sdb3
```